SGH
Szkoła Główna
Handlowa
w Warszawie

# Klasyfikacja sygnału elektrokardiograficznego w czasie rzeczywistym przy użyciu głębokich sieci neuronowych i architektury strumieniowej

Justyna Weber, 141189
Praca magisterska pod kierunkiem naukowym dr Sebastiana Zająca

Czerwiec 2026, Warszawa

# Wprowadzenie i motywacja biznesowo-medyczna

- Problem zdrowia publicznego
  Choroby układu krążenia odpowiadają za ok. 32% zgonów na świecie
- Zjawisko „Silver Tsunami”
  starzenie się społeczeństw przeciąża opiekę zdrowotną
- Koszt ekonomiczny
  leczenie chorób serca kosztuje Unię Europejską 169 mld euro rocznie

Rozwiązanie: Przesunięcie ciężaru diagnostyki ze szpitali do telemonitoringu domowego i urządzeń wearable.

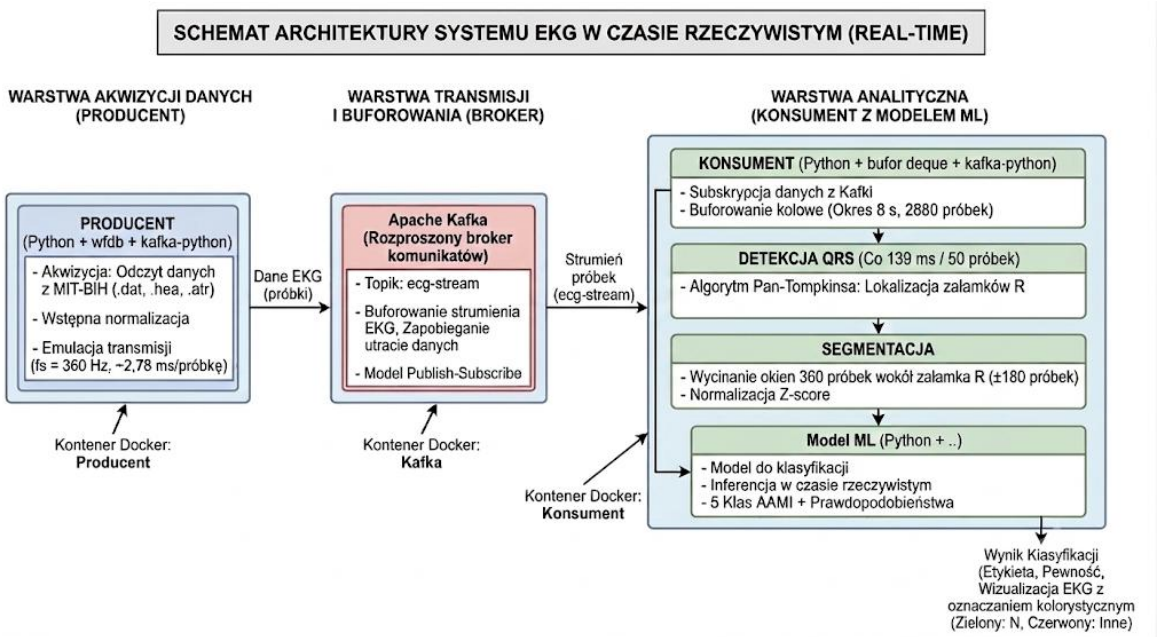
# Cel, zakres i wyzwania analityczne

1. Cel - zaprojektowanie, implementacja i ewaluacja potoku strumieniowego oraz porównanie modeli 1D-ResNet i CNN-BiLSTM,

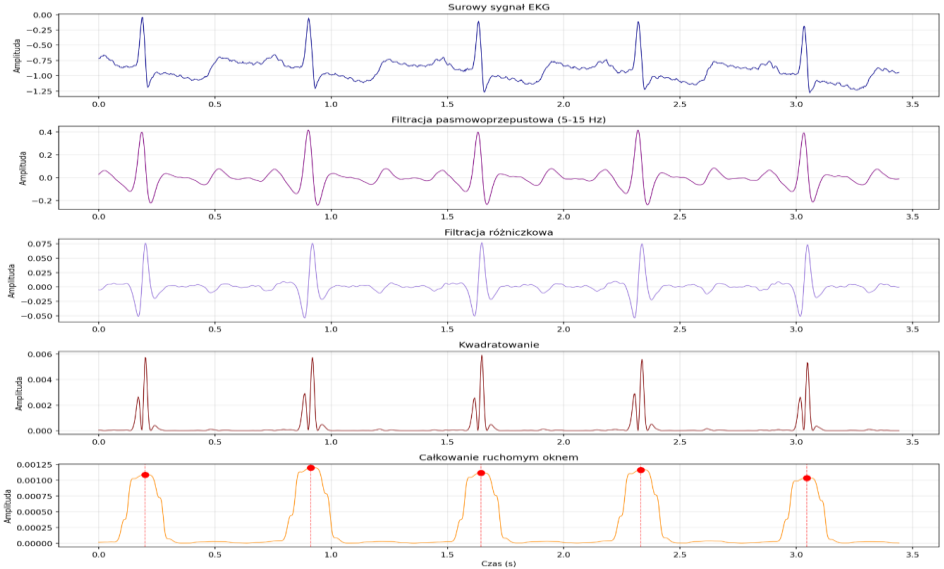
2. Wyzwanie 1 - Skrajna asymetria bazy MIT-BIH klasa prawidłowa (N) stanowi ponad 92% danych,

3. Wyzwanie 2 - Zastosowanie rygorystycznego protokołu podziału pacjentów (*inter-patient protocol* de Chazala) w celu eliminacji wycieku danych.

# Architektura systemu



# Przetwarzanie wstępne: Algorytm Pan-Tompkinsa i standaryzacja




- System analizuje dane w paczkach co 50 próbek (ok. 139 ms), unikając przeciążenia CPU,
- Algorytm Pan-Tompkinsa (filtracja pasmowa 5-15 Hz, różniczkowanie, kwadratowanie, całkowanie),
- Wycinanie segmentów o długości 360 próbek wokół załamka R,
- Standaryzacja Z-Score:

$$X_{scaled} = \frac{X - \mu}{\sigma + \epsilon}$$

# Architektura testowanych modeli

## Model 1: 1D-ResNet (Sieć Rezydualna)

- Jednowymiarowe sploty FIR wzdłuż osi czasu,
- Połączenia skrótowe (*Skip Connections*) stabilizujące gradient,
- Konwolucje rozszerzone (*Dilated Convolutions*) zwiększające pole recepcyjne.

## Model 2: CNN-BiLSTM (Model Hybrydowy)

- Warstwy splotowe (CNN stem) jako ekstraktor cech lokalnych,
- Dwukierunkowy LSTM (BiLSTM) do analizy kontekstu czasowego,
- Analiza przyczynowa ($\mathrm{P} \rightarrow QRS \rightarrow T$) i retrospektywna ($T \rightarrow QRS \rightarrow P$).

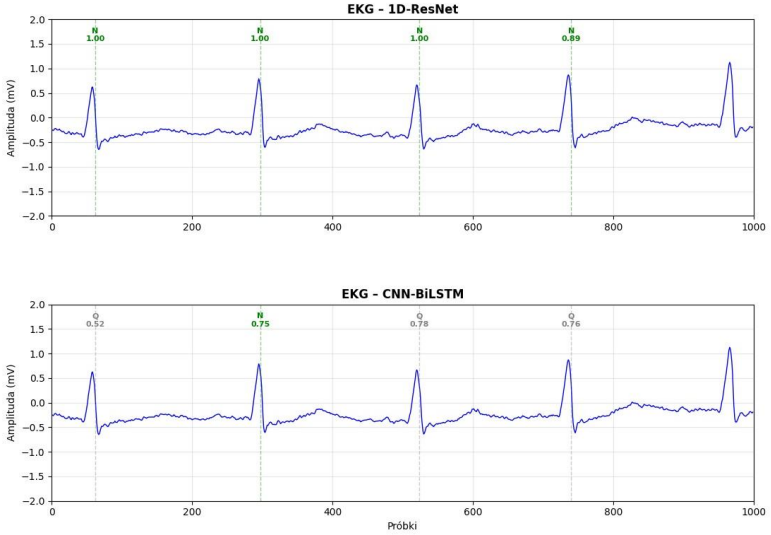
Kompensacja imbalansu: Dynamiczne ważenie funkcji kosztu (class weighting)

# Wyniki eksperymentalne na zbiorze testowym DS2

*Zbiorcze porównanie metryk efektywności testowanych modeli*

| Metryka | ResNet (1D-CNN) | BiLSTM (CNN+LSTM) |
|---|---|---|
| Ogólna dokładność | 72,7% | 77,2% |
| N - czułość | 75,2% | 80,3% |
| V - czułość | 78,9% | 88,6% |
| S - czułość | 4,7% | 5,1% |
| F - czułość | 68,6% | 9,4% |
| Q - czułość | 0% | 0% |

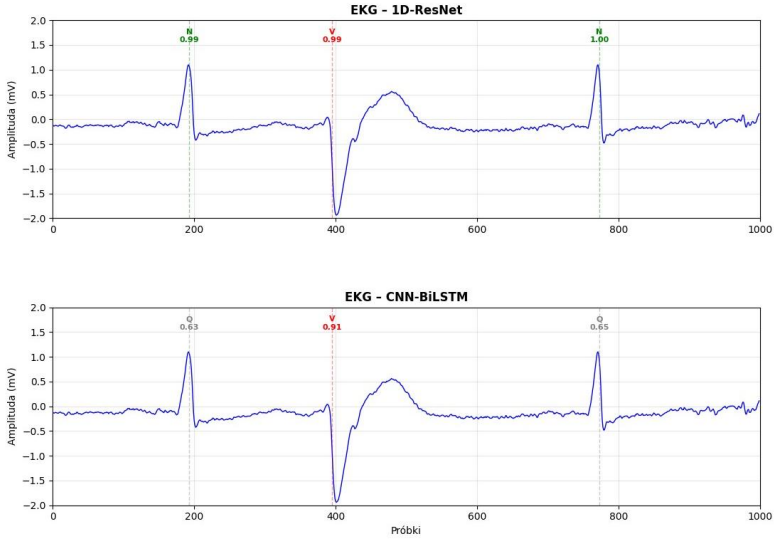
# Studium Przypadku dla Klasy N




- Sekwencja miarowych, prawidłowych pobudzeń zatokowych,
- 1D-ResNet: Wyjątkowa stabilność rytmu podstawowego (pewność predykcji: 1.00, 1.00, 1.00, 0.89),
- CNN-BiLSTM: Tendencja do silnej destabilizacji i nadklasyfikacji – błędne przypisanie 3 z 4 pobudzeń do klasy mniejszościowej Q.

Uboczny efekt silnego ważenia klas w strukturze rekurencyjnej, hiperwrażliwość na minimalny szum pacjenta

# Studium Przypadku dla Klasy V




- Ostry incydent komorowy otoczony zdrowymi pobudzeniami,
- Oba modele bezbłędnie wychwytują skurcz komorowy (Pewność ResNet: 0.99, BiLSTM: 0.91),
- ResNet zachowuje stabilność strukturalną, BiLSTM ponownie nadinterpretuje zdrowe pobudzenia jako klasę Q,

Mimo wyższej globalnej dokładności BiLSTM na zbiorze testowym, w realnym działaniu medycznym to 1D-ResNet jest bezpieczniejszy i stabilniejszy, ponieważ ogranicza fałszywe alarmy.

# Podsumowanie i kierunki dalszych badań

Wnioski:

- Cele pracy zostały w pełni zrealizowane, potok technologiczny Kafka+Docker udowodnił pełną gotowość operacyjną,
- Wybór modelu zależy od priorytetu systemu (BiLSTM – maksymalny recall dla klasy V; ResNet – stabilność kliniczna i brak fałszywych alarmów)

Możliwe kierunki rozwoju:

- Budowa modeli kaskadowych i zespołowych (*Ensemble models*) łączących zalety obu sieci,
- Wdrożenie szybkiej adaptacji specyficznej dla pacjenta (*patient-specific adaptation*) w pierwszych minutach sygnału.



SGH
Szkoła Główna
Handlowa
w Warszawie

# Dziękuję za uwagę!